T5 公共热身：三方法对比初探

课程/小组：知识图谱技术与应用 • 网络工程实践（T5 公共热身）

日期：2026-10-21

配套材料：report/T5 公共热身-运行日志.txt、scripts/run_t5.cmd

1. 热身目标与语料

在正式做题目二之前，先用脚手架自带的 T5（TCP/IP 协议栈与 RFC 规范）把"本体 → 三方法抽取 → 融合 → 建图 → 评测 → KG 问答"整条链路跑一遍，暴露工程问题。语料为 5 篇公开 RFC（2119、768、791、8200、9293），共 473,914 字节、11,271 行；本体 11 类、13 个关系，自检 0 问题；抽样金标准 23 个实体、18 条关系。

2. 一键运行

```
scripts\run_t5.cmd
```

脚本依次执行本体生成与自检、方法 A（规则/词典）、方法 B（字符级 BIO 序列标注 + 关系分类）、方法 C（本体约束 LLM，读取已保存输出）、融合、建图、金标准检查与评测、8 题 KG 问答、MCP 冒烟测试。运行环境 Python 3.14.4，全程退出码 0，MCP 4 个工具全部通过。

3. 三方法对比

方法	实体 P	实体 R	实体 F1	三元组 P	三元组 R	三元组 F1	证据覆盖率
A 规则/词典	0.0769	0.9565	0.1424	0.1429	0.2778	0.1887	1.0
B 序列标注	0.0691	0.8261	0.1275	0.0296	0.2222	0.0523	1.0
C 本体约束 LLM	**0.6286**	0.9565	**0.7586**	**0.5161**	**0.8889**	**0.6531**	1.0
融合	0.0647	0.8696	0.1205	0.1585	0.7222	0.2600	1.0

金标准只有 18 条关系，precision 是**下界**：方法抽出的、金标准未收录的正确知识也会被记为误报，因此本表只用于横向比较，不代表最终抽取质量。

三方法的失败模式差异明显：

- A 召回最高（实体 0.9565），但把正文里出现的每个 RFC 编号、章节标题都当成实体，384 个实体对 23 个金标准实体，精度被摊薄到 0.0769。规则方法的成本最低，但"宁多勿少"的词典匹配需要后置过滤。
- B 抽出 3,473 个实体、521 条关系，实体精度 0.0691。字符级 BIO 在 RFC 的目录行、页眉和长标题上大量误切，说明"序列标注 + 高阈值"并不能代替领域边界定义；训练句仅 612 句，留出文档为 rfc9293。
- C 只输出 41 个实体、31 条关系，四项 P/R/F1 均为最高，证据覆盖 31/31、越界 0。但其输出是预先生成并保存的文件，本表没有计入调用时延与费用；小样本上 LLM 的优势也不能直接外推。

4. 融合、质量门与投票可信度

融合按 (头, 关系, 尾) 去重投票，权重为规则 1.0、模型 0.8、LLM 1.2。质量门丢弃 218 条标签不合法、1 条受控词表外条目；1 条域/值域违规边降权 0.5 倍但保留。对齐后 309 个实体、487 条三元组。

命中方法数	三元组数	精确率	召回	F1
1 票	57	0.1404	0.4444	0.2133
2 票	21	0.0952	0.1111	0.1026
3 票	4	**0.7500**	0.1667	0.2727

3 票精度 0.75 说明"多方法一致"确实能筛出高可信边，但只有 4 条，覆盖率极低；2 票精度反而低于 1 票，因为规则与模型在"RFC 编号/章节标题"上的错误高度相关，投票把同一类噪声重复计数。结论是：**投票数只有在实体归一化做对之后才等于置信度**，这直接决定了题目二必须用官方 ID 做一级键，而不是按字符串投票。

图谱结构也暴露了一个具体缺陷：RFC:rfc8200 节点存在，但 obsoletes 边的源端却落在裸 rfc 节点上，形成 RFC:rfc 垃圾枢纽，且 rfc2460 obsoletes rfc 方向明显反了。这是"没有官方 ID 约束、按文本表面建边"的典型后果。

5. KG 问答初探

8 道题中可回答率 0.5，平均三元组覆盖率 0.3334。按题型归并：

题型	题数	覆盖率	观察
首部字段（TCP/IPv6/UDP）	3	0.667 – 1.0	字段边能检索到；预置答案中夹带的假句被验证器逐句抓出，幻觉率 0.5
官方编号（RFC 8200/RFC 9293）	2	0	问句关键词被拆成 RFC 与 8200，RFC 节点根本没进候选
分层/关系（TCP 所在层、TCP – 传输层）	2	0	图里存在 TCP --operates_at--> Transport Layer，但被 15 条高置信 has_field 边挤出 top-12
图谱外（等保三级）	1	—	正确拒答"图谱中无此知识"，幻觉率 0

两个检索缺陷都不是图谱缺边：一是 keywords() 按空白切词，破坏了 "RFC 8200" 这类官方编号；二是按置信度排序后硬截断，低置信但答案相关的边被挤掉。前者说明查询解析必须保护 ID 片段，后者说明检索应按关系意图加权，而不是只看置信度。

验证器采用保守口径：答案句只要不能在某条检索到的三元组里找到实体与关系词支撑，就记为"未支撑"。因此"RFC 8200 取代了 RFC 2460"这类**事实正确但图谱没有对应边**的答案也会被计入幻觉率 1.0。报告里必须把"未支撑率"与"事实错误率"分开写，否则会高估幻觉。

6. 对题目二的启示

1. **官方 ID 先行**：先用 CVE/CWE/CPE/ATT&CK 官方编号归一化，再谈投票、置信度和消歧。
2. **金标准与抽取解耦**：题目二的金标准从官方结构化字段全量构造，不 import 任何抽取方法，避免"用答案评答案"。
3. **投票不是置信度**：T5 的 2 票桶已证明，相关性错误会让票数虚高；必须叠加域/值域校验和来源权重。
4. **检索要识别 ID**：问句切词应保护 RFC 8200、CVE-2021-44228、T1059.001 这类片段，并按问句意图选择关系。
5. **幻觉率单独算**：单方法图与融合图用同一题库、同一验证器对比，并明确"未支撑"口径。

7. 局限

T5 使用脚手架自带的小型示意语料与抽样金标准（18 条关系），方法 C 读取的是预保存输出，本报告只验证链路可运行和比较方法学，不构成对三种方法最终效果的结论；这些结论需要在题目二的 15 篇文档、40 个 CVE、389 个金标准实体和 782 条关系上重新检验。